


Measuring bias in Indian newspapers

Arun Varghese

Inspiration

- Gentzkow & Shapiro 2010
- First economics paper to use text data in an innovative way
- ‘What drives media slant?’: supply side or demand side?
- Intermediate step: need to quantify ‘slant’ or bias
- Done by comparing text from congressional record (ideology labeled using constituency vote share) against newspaper text




My project

- Similar exercise with Malayalam-language newspapers in the Indian state of Kerala
- Want to get better at language, learn something about politics
- Challenges: dealing with non-standard text, not many pre-existing NLP resources, agglutinative language

Kerala

- South-western tip of India
- First state to democratically elect communist government
- Now, multiple parties but dominated by two coalitions: Left Democratic Front (LDF) and congress-led United Democratic Front (UDF) who have traded majority power in legislature since Kerala founding





More background

- Legislative Assembly: Niyamasabha (140 elected members)
- Last election in 2011
- Print media widely consumed
- Bias is widely thought to exist – some papers are owned by certain parties



Method

- Get text from legislative hearings
- Label by political slant/ideology from vote share data
- Generate text features and build regression model of slant
- Get newspaper article text and fit to model to get slant score for each newspaper

Data

- Text of legislative meetings available online
 - But mostly as PDFs
 - But ‘Question and Answer’ sessions available on html pages (bad sample?)
 - Scraped a month’s worth of these (labeled with speaker/s)
- Vote share data from 2011 election available online
- Text from newspaper articles available online

THIRTEENTH KLA - 16th SESSION
STARRED QUESTIONS AND ANSWERS
(To read Questions please enable Unicode-Malayalam in your system)
(To read answers Please **CLICK** on the Title of the Questions)

Questions and Answers

[ലൈറ്റ് മെട്രോ പദ്ധതി](#)

ശ്രീ.എം.എ. വാഹിദ്
കെ.കുര്യൻ
എ.എ.ജോർജ്ജ്
ആർ. സെൽവരാജ് : താഴെ കാണുന്ന ചോദ്യങ്ങൾക്ക് പൊതുമരാമത്ത് വകുപ്പുമന്ത്രി സ
സംസ്ഥാനത്ത് ലൈറ്റ് മെട്രോ നടപ്പാക്കാൻ എന്തെല്ലാം കർമ്മ പദ്ധതികളാണ് ആവിഷ്കരിച്ചത്?
എന്തെല്ലാം ഉദ്യോഗ്യ ലക്ഷ്യങ്ങളാണ് ഇത് വഴി കൈവരിക്കാനുദ്ദേശിക്കുന്നത്;
ഇത് നടപ്പാക്കാൻ ഭരണതലത്തിൽ എന്തെല്ലാം നടപടികൾ സ്വീകരിച്ചിട്ടുണ്ട്?

[ആഗോള വിദ്യാഭ്യാസ സംഗമം](#)

ശ്രീ.എ. പ്രദീപ്കുമാർ
എ.കെ.ബാലൻ
കെ.സുരേഷ് കുറുപ്പ്

CTIONS APPS f t G+ RSS SUBSCRIBE: DIGITAL 0 SIG

5 APRIL 2016 FRIDAY 12:10 AM IST

manoramaonline

E-PAPER, ONMANORAMA (ENGLISH), MANORAMANETV, BLOGS, CHUTTUVAATTOM (DISTRICTS), GULF

Thiruv
—Custo

NEWS OBIT MOVIE TECH SPORTS LIFE ASTRO HEALTH AUTO MUSIC SHE VEEDU ENVIRONMENT CHILDREN

NG NOW: Vishu Special Assembly Election Barcelona IPL

Search in Malayalam or English

ST NEWS >

പൂർ പൂരം വെടിക്കെട്ടിന് ഉപാധികളോടെ
മുതിർ; ശബരിമലയിൽ വേണം

കൊച്ചി • തൃശ്ശൂർ പൂരം വെടിക്കെട്ടിനുള്ള
നിയന്ത്രണങ്ങളിൽ ഉപാധികളോടെ
ഇളവനുദിക്കാൻ ഹൈക്കോടതി തീരുമാനിച്ചു.
പൂരം തൃശ്ശൂരിന്റെ സാമൂഹിക ജീവിതത്തിന്റെ
ഒന്നാണ്...

വടക്കിന്റെ സംഭാവനകളെ പൂർത്തിയാക്കി കോൺഗ്രസ്
തൊട്ടാഴ്ച പരയണം: മോദി

മൗ • ഇന്ത്യൻ ഭരണഘടനാ ശിക്ഷിതായ ഡോ.
ബി.ആർ.അബ്ദുക്കുറുപ്പ് സംഭാവനകളെ

EDITOR'S PICK

എൻഡോർ എന്ന
വിജയഗാഥ

പഴയ വിജയ്; പുതിയ
'തെനി'

ASSET HOMES ASSEMBLY ELECTION 20

NRI NEWS > Customiz

US manorama.com

ജൂബിലി നിറവിൽ കൃത്യ
റവ.പാ. ആന്റണി തുണ്ട

ഷിക്ക്
കാശ
ബാർ
ത്തുവ
രൽ വികാരിയായും, മൂന്നു വർ
കാരി ജനറലായും സ്മൃതൃ
നുഷ്ടിച്ച ശേഷം ഇപ്പോൾ...

Feature engineering and selection

- Represent legislative text as bag of words
- Drop 'stop words', rare words (have to define own stop words)
- Each document has ideology label
- Use chi-squared test to find words/phrases most representative of a particular party

$$\chi^2 = \sum \frac{(\textit{Observed} - \textit{Expected})^2}{\textit{Expected}}$$

- Intuition: If we assumed party and words used were randomly assigned, which co-occur more/less often than we would expect?

Gentzkow & Shapiro

Democrats:

- 'Workers rights'
- 'Poor people'
- 'Estate tax'

Republicans:

- 'Stem cell'
- 'Saddam Hussein'
- 'Death tax'

Gentzkow & Shapiro

Democrats:

- ‘Workers rights’
- ‘Poor people’
- ‘Estate tax’

Republicans:

- ‘Stem cell’
- ‘Saddam Hussein’
- ‘Death tax’

Me

Lots of procedural words, question words, etc

LDF:

- അഗ്രികൾച്ചർ (agriculture)
- ആദിവാസി (adivasi)
- More negative words [അവബോധ, അനധികൃത]

UDF:

- Many procedural/question words
- അഞ്ചുവർഷങ്ങളിലായി വകയിരുത്തി (For five years, we’ve been here)
- And variations

Ongoing work

- Tinkering with model – not getting great explanatory power in-sample
- Use article text to help generate features
- Fit article text and get slant of newspapers!

Thanks!